VaR : Value at Risk
Perte potentielle maximale d'un investisseur sur la valeur d'un actif / portefeuille qui ne devrait être atteinte qu'avec une probabilité donnée sur un horizon donné.
= La pire perte attendue sur un horizon de temps donné pour un certain niveau de confiance α, généralement 5%.

3 paramètres à spécifier pour pouvoir utiliser la VaR :

- Distribution des variations de l'actif/portefeuille ;
- Niveau de confiance, généralement 5% ;
- Période de détention de l'actif.

Hypothèses nécessaire au calcul de la VaR :

- Normalité des distributions des variations de l'actif/portefeuille ;
- $VaR(N\ jours, \alpha) = \sqrt{N} \times VaR(1\ jour, \alpha)$;
- Le rendement moyen de l'actif/portefeuille est nul pour la période considérée.

Méthodes de calcul de la VaR :

1. Historique : calcul de la VaR sur la base des variations précédentes de l'actif/portefeuille (pas besoin de connaître la distribution de l'actif/portefeuille, mais l'historique considéré doit être ni trop court ni trop long)
2. Paramétrique : $VaR(1j, \alpha) = valeur_{actif} \times \sigma_{actif,1j} \times z_{1-\alpha}$ | où $\sigma_{actif,1j}$ est la volatilité quotidienne de l'actif (nous choisissons 20 – 44j, ou EWMA), et $z_{1-\alpha}$ le quantile d'ordre 1-α d'une loi normale.
   Utilisation d'une matrice de variance-covariance dans le cas d'un portefeuille. (suppose une distribution normale, et une relation linéaire entre l'actif/portefeuille et le marché).
3. Monte-Carlo

L'utilisation d'une des méthodes de calcul doit pouvoir vérifier les hypothèses sous-jacentes à la méthode ; nous devons vérifier que ces hypothèses sont vérifiées par nos données.

Dans un premier temps, nous considérons un portefeuille composé d'une seule action, par souci de simplicité. Dans un second temps, nous améliorons ce portefeuille une fois que ce premier prototype nous semble solide.

Calcul de la Var paramétrique

Principe :

1. On récupère le cours de l'action, et les cours précédents (autant que l'on souhaite, au nombre de n) ;
2. On calcule les n-1 rendements journaliers à partir des cours passés. Pour cela, on utilise les rendements logarithmiques (pour bénéficier des propriétés additives de la fonction logarithme) : $r_log_t = \log\left(\frac{cours_t}{cours_{t-1}}\right) \forall t = \{2, \dots, n\}$;
3. Avec ces rendements journaliers, on calcule la volatilité journalière : $\sigma_{journalière} = \sqrt{\frac{1}{n-2}\sum_{i=2}^{n}(r_log_t - \overline{r_log_t})^2}$;
4. Pour un horizon de T jours, la VaR paramétrique, à un niveau de confiance de $1-\alpha$, se calcule comme suit : $VaR_{T\ jours} = VaR_{1\ jour} \times \sqrt{T} = S_0 q \times \sigma_{journalière} \times z_\alpha \times \sqrt{T}$ où
   $S_0 q$ = taille de la position sur l'action
   z_α = quantile d'ordre α de la loi N(0,1)

Note : l'historique des cours utilisé n'a pas nécessairement à être de la même taille que l'horizon de jours T.

Hypothèses (pour un portefeuille constitué d'une seule action) :

1. Normalité des rendements : les rendements suivent une loi normale ;
2. Stationnarité de la moyenne et de la variance sur l'horizon du calcul : la moyenne et la variance des rendements sont constants sur l'horizon du calcul ;
3. Liquidité parfaite : pouvoir clôturer sa position à tout moment, sans devoir subir une perte additionnelle liée au bid-ask spread (qui peut être plus ou moins conséquente).

<u>Ici, nous ne vérifions que l'hypothèse de normalité des rendements, dans le cas d'un portefeuille constitué que d'une seule action (pour simplifier).</u>
Pour cela, nous introduisons les outils suivants :

- Skewness et Kurtosis ;
- Test de Jarque-Bera et Test de Shapiro-Wilk ;
- Diagramme Q-Q.

Skewness (coefficient d'asymétrie en français) : moment d'ordre 3 de la version centrée réduite d'une variable aléatoire : $soit\ X\ une\ variable\ aléatoire\ de\ moyenne\ \mu\ et\ de\ variance\ \sigma^2. Le\ skewness\ S := \mathbb{E}[\left(\frac{X-\mu}{\sigma}\right)^3]$. C'est une mesure de l'asymétrie d'une variable aléatoire par rapport à sa moyenne.
3 cas :

- S = 0 : la distribution est symétrique par rapport à sa moyenne (ex : loi normale N(0,1))
- S > 0 : la distribution admet une queue plus longue à droite, donc les données sont plus concentrées à gauche (ex : loi khi-deux $\chi^2(3)$)
- S < 0 : la distribution admet une queue plus longue à gauche, donc les données sont plus concentrées à droite (ex : loi Beta(8,2))

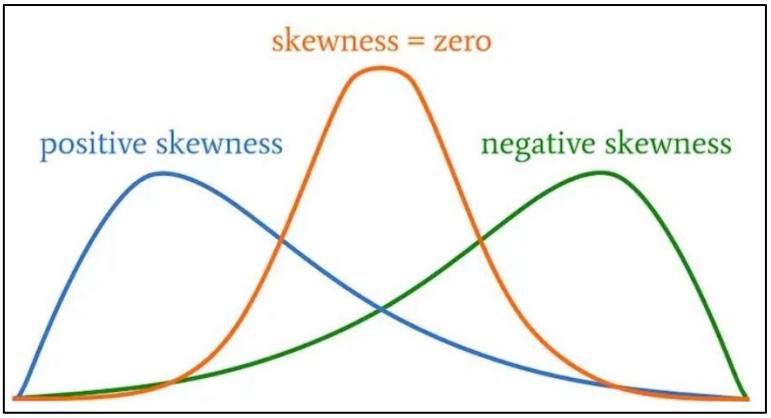

Source : Skewness: “Unpacking the Distribution shape to know the direction of outliers”

Kurtosis (coefficient d’aplatissement) : moment d’ordre 4 de la version centrée réduite d’une variable aléatoire. C’est la concentration des données autour du centre.
$Soit\ X\ une\ variable\ aléatoire\ de\ moyenne\ \mu\ et\ de\ variance\ \sigma^2. Le\ kurtois\ (non\ normalisé)\ \kappa \coloneqq \mathbb{E}[\left(\frac{X-\mu}{\sigma}\right)^4]$.
On utilise souvent l’excès de kurtosis ("excess kurtosis") pour comparer le kurtosis de la variable avec celle d’une loi normale (dont le kurtosis est de 3) : $excess\ kurtosis\ \kappa' \coloneqq \kappa - 3$.

3 cas :

- $\kappa' = 0$: kurtosis identique à celle d’une loi normale (la variable est dite "mésokurtique"). La concentration des données autour du centre est la même que celle d’une loi normale.
- $\kappa' > 0$: kurtosis supérieur à celle d’une loi normale (la variable est dite "leptokurtique"). La concentration des données autour du centre est plus faible que celle d’une loi normale (forme de pic vers le centre, et valeurs extrêmes plus fréquentes).
- $\kappa' < 0$: kurtosis inférieur à celle d’une loi normale (la variable est dite "platykurtique"). La concentration des données autour du centre est plus forte que celle d’une loi normale (forme "aplatie" de la distribution).

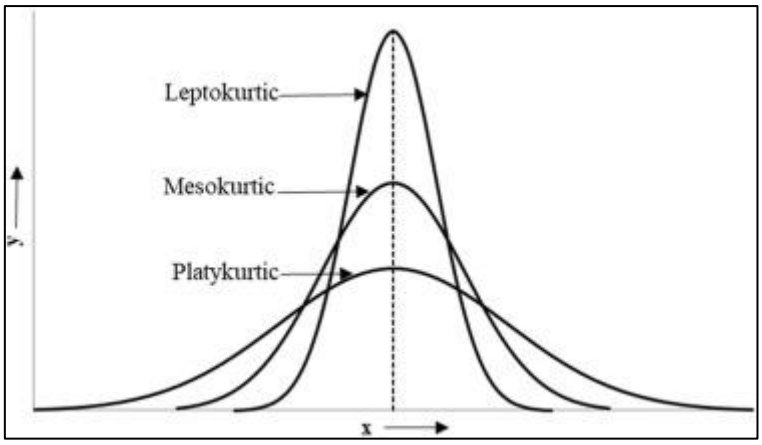

Source : Platykurtic Distribution: Working Beyond Normality

Note : ce graphique est trompeur, puisqu’il montre au lecteur que la variable platykurtique semble prendre plus fréquemment des valeurs extrêmes que la variable leptokurtique. En réalité, c’est l’inverse. En effet, il faut raisonner en termes d’écart-types autour du centre : au-delà de $\pm 2\sigma$, la concentration relative des données (=pourcentage des données dans ces extrémités) est plus forte dans une courbe leptokurtique que platykurtique.

Test de Jarque-Bera : compare simultanément le skewness et kurtosis des données à celle d'une loi normale. <u>Il est utilisé lorsque l'on dispose de grands échantillons</u>.

$H_0 \coloneqq S = 0 \; et \; \kappa' = 0 \; (les \; rendements \; suivent \; une \; loi \; normale)$

$H_1 \coloneqq S \neq 0 \; et/ou \; \kappa' \neq 0 \; (les \; rendements \; ne \; suivent \; pas \; une \; loi \; normale)$

Sous H_0, la statistique est : $JB = \frac{n}{6}(S^2 + \frac{\kappa^2}{4})$ où

- $JB \sim \chi^2(2)$,
- n est le nombre d'observation.

La règle de décision est la suivante : si la p-value < 0.05, on rejette H_0; sinon, on ne rejette pas H_0.

Test de Shapiro-Wilk : calcule la corrélation entre les données ordonnées et les quantiles théoriques d'une loi normale. <u>Il est utilisé lorsqu'on dispose de petits échantillons</u>.

$H_0 \coloneqq (X_i)_{1 \leq i \leq n} \; sont \; i.i.d \; et \; suivent \; une \; loi \; normale$

$H_1 \coloneqq (X_i)_{1 \leq i \leq n} \; ne \; suivent \; pas \; une \; loi \; normale$

Sous H_0, la statistique est : $W = \frac{[\sum_{i=1}^{n} a_i x_{(i)}]^2}{\sum_{i=1}^{n}(x_i - \bar{x})^2}$ où :

- W suit une loi de probabilité dont on ne connaît pas la forme (car trop complexe à formaliser)
- a_i est un coefficient calculé à partir des espérances et de la matrice de covariance des statistiques d'ordre d'une loi normale N(0,1)
- $x_{(i)}$ est la i^{ème} valeur de l'échantillon trié par ordre croissant,
- $\bar{x}$ est la moyenne empirique.

En pratique, on utilise l'approximation de Royston pour calculer la p-value et conclure.

La règle de décision est : si la p-value < 0.05, on rejette H_0; sinon, on ne rejette pas H_0.

Calcul de la statistique W à la main :

3. Summary of operational information

The objective of this section is to bring together all the tables and descriptions needed to execute the W test for normality. This section may be employed independently of notational or other information from other sections.

The object of the W test is to provide an index or test statistic to evaluate the supposed normality of a complete sample. The statistic has been shown to be an effective measure of normality even for small samples ($n < 20$) against a wide spectrum of non-normal alternatives (see §5 below and Shapiro & Wilk (1964*a*)).

The W statistic is scale and origin invariant and hence supplies a test of the composite null hypothesis of normality.

To compute the value of W, given a complete random sample of size n, $x_1, x_2, \ldots, x_n$, one proceeds as follows:

(i) Order the observations to obtain an ordered sample $y_1 \leqslant y_2 \leqslant \ldots \leqslant y_n$.

(ii) Compute

$$S^2 = \sum_1^n (y_i - \bar{y})^2 = \sum_1^n (x_i - \bar{x})^2.$$

(iii) (*a*) If n is even, $n = 2k$, compute

$$b = \sum_{i=1}^{k} a_{n-i+1}(y_{n-i+1} - y_i),$$

where the values of a_{n-i+1} are given in Table 5.

(*b*) If n is odd, $n = 2k+1$, the computation is just as in (iii) (*a*), since $a_{k+1} = 0$ when $n = 2k+1$. Thus one finds

$$b = a_n(y_n - y_1) + \ldots + a_{k+2}(y_{k+2} - y_k),$$

where the value of y_{k+1}, the sample median, does not enter the computation of b.

(iv) Compute $W = b^2/S^2$.

(v) 1, 2, 5, 10, 50, 90, 95, 98 and 99 % points of the distribution of W are given in Table 6. *Small values of W are significant*, i.e. indicate non-normality.

(vi) A more precise significance level may be associated with an observed W value by using the approximation detailed in Shapiro & Wilk (1965*a*).

Source : An analysis of variance test for normality (complete samples), By S.S Shapiro AND M.B Wilk

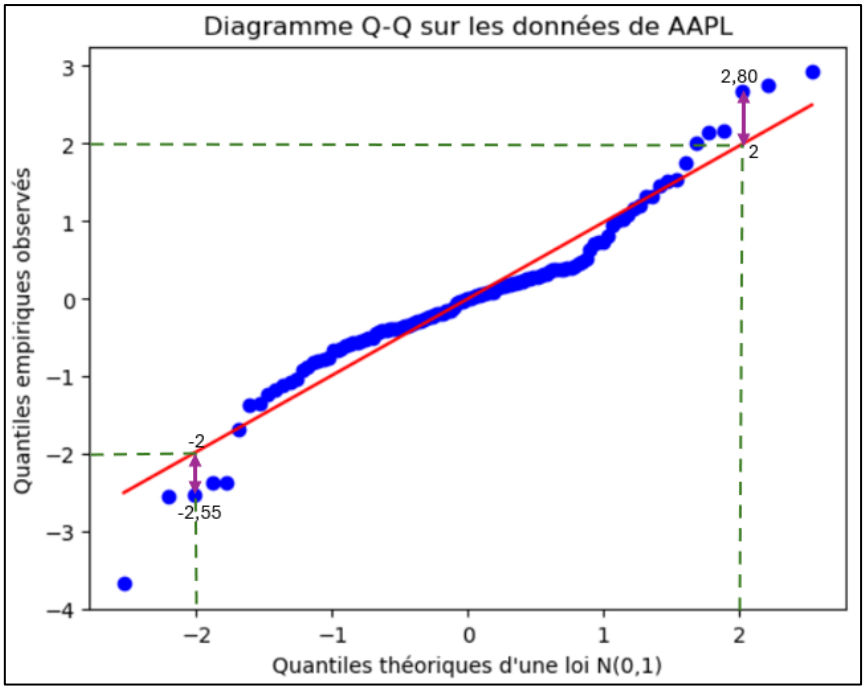

Interprétation du diagramme Q-Q :
Si les données centrées-réduites suivaient une loi normale N(0,1), alors ça signifierait que le quantile théorique d'ordre 2,275% est de -2, et pour le quantile empirique d'ordre 2,275% on devrait aussi avoir -2.
Mais là on remarque que le point centré-réduit est en-dessous de la droite rouge pour le quantile théorique d'ordre 2,275% : la valeur du quantile empirique d'ordre 2,275% est ici plus faible et différent que ce qu'il devrait être lorsque les données suivaient une loi normale (-2.55 environ contre -2 prévu si les données suivaient effectivement une loi normale).

De même, pour l'ordre de 97,725%, le quantile théorique est de 2, et le quantile empirique devrait aussi être de 2 (si les données centrées-réduites suivaient une loi normal standard).
Mais ici, on observe que le quantile empirique d'ordre 97,725% est au-dessus de la droite (donc de la valeur qu'il devrait prendre s'il la distribution était normale, donc que l'on surestime ici).

Deux conclusions :

- D'une part, le quantile empirique d'ordre 2,275% est ici plus faible que le quantile théorique d'une loi N(0,1). Cela signifie qu'on a théoriquement 2,275% de chances de tomber sur une valeur inférieure à -2, mais qu'on a ici empiriquement 2,275% de chances de tomber sur une valeur inférieure à -2,55.
  Donc on a empiriquement plus de 2,275% de chances de tomber sur une valeur inférieure à -2. La loi normale sous-estime les variations négatives extrêmes.
- D'autre part, le quantile empirique d'ordre 97,725% est ici plus élevé que le quantile d'ordre 97,725% d'une loi N(0,1). Cela signifie qu'on a théoriquement 97,725% de chances d'avoir une valeur inférieure à 2, mais qu'on a empiriquement 97,725% de chances d'avoir une valeur inférieure à 2,8 (environ).
  Donc on a empiriquement plus de chances d'avoir une variation positive extrême que ce que prévoit la loi normale. La loi normale sous-estime les variations positives extrêmes.

Ainsi, la loi normale sous-estime à la fois les variations négatives et positives extrêmes. Les queues extrêmes sont plus épaisses par rapport à celles d'une loi normale : la distribution est leptokurtique.

Il y a plus de points négatifs extrêmes (5 points) que de points positifs extrêmes (3 points); la distribution est asymétrique, avec une queue plus longue vers la gauche (valeurs négatives) que vers la droite (valeurs positives) : le skewness est négatif.

En utilisant la Var paramétrique, on sous-estime les variations extrêmes.
Le risque de pertes est plus grand qu'il n'y paraîtrait avec la VaR paramétrique.

Calcul de la VaR historique

Principe :

1. On prend les variations (en %) sur une période de temps donnée,
2. On les trie du plus petit au plus grand,
3. On regarde le quantile d'ordre α pour une VaR à l'ordre α.

Hypothèses :

- Stationnarité : cette méthode suppose que les rendements suivent une même distribution au cours du temps, donc que la distribution future est la même que la distribution passée.
- Absence d'autocorrélation des rendements : les rendements/variations sont supposées indépendantes dans le temps, car sinon le tri perd son sens statistique (= les données observées ne seraient plus les observations de variables $(X_i)_{1\leq i\leq n}$ i.i.d si elles étaient dépendantes).
- La période considérée contient suffisamment d'évènements extrêmes pour estimer correctement la queue de distribution.

Définition de la stationnarité : une série (de données) est dite "stationnaire" si ses propriétés statistiques (moyenne, variance) ne changent pas dans le temps.
Si la série n'est pas stationnaire, c'est qu'elle possède ce qu'on appelle une "racine unitaire" (elle a une tendance imprévisible sur le long terme).

Pour vérifier la stationnarité des données, on peut regarder la volatilité sur la période.
Pour ce faire, on peut se servir de graphiques, ou de tests.

Pour les graphiques, on peut procéder comme suit :

1. On calcule l'écart-type des rendements sur une fenêtre glissante de taille fixe (typiquement 21 jours, soit un mois boursier) ;
2. On trace cette volatilité au fil du temps ;
3. On conclut : si la série est stationnaire, cette volatilité doit fluctuer autour d'un niveau constant sans tendance ni rupture brutale durable.

Pour les tests, on peut utiliser les tests ADF et KPSS.

- Test ADF (Augmented Dickey-Fuller) : la série temporelle est-elle stationnaire ou non ?

On considère la série $\Delta x_t = \alpha + \beta t + \gamma x_{t-1} + \sum_{i=1}^{p} \delta_i \Delta x_{t-i} + \varepsilon_t$, où

- $\Delta x_t = x_t - x_{t-1}$;
- γ est le coefficient d'intérêt (= vitesse à laquelle la série revient à sa moyenne) ;
- $\sum_{i=1}^{n} \delta_i \Delta x_{t-i}$ sont les "termes augmentés" (ils sont utilisés pour éliminer l'autocorrélation des résidus, donc rendre le test plus fiable) ;
- p est le nombre de termes, trouvé à partir des critères AIC et BIC.

Lorsque $\gamma = 0$, on parle de "racine unitaire" : la série ne revient jamais à sa moyenne/il n'y a pas de variations futures qui viennent "compenser" pour ramener la série au niveau de sa moyenne.
Lorsque $\gamma < 0$, on parle de "stationnarité" : plus le niveau précédent x_{t-1} était élevé, plus la variation actuelle Δx_t sera négative pour "compenser" et ramener la série vers le bas (mécanisme d'auto-correction).

$H_0 \coloneqq \gamma = 0$ (non stationnarité)
$H_1 \coloneqq \gamma < 0$ (stationnarité, plus le niveau précédent x_{t-1} était élevé, plus la variation actuelle Δx_t sera négative pour "compenser" et ramener la série vers le bas. C'est un mécanisme d'auto-correction)
Sous H_0, la statistique est : $ADF = \frac{\hat{\gamma}}{\widehat{\sigma_{\hat{\gamma}}}}$ suit une loi de Dickey-Fuller.
Comme la statistique prend une valeur négative, la règle de décision est :
- Si $ADF \leq DF_{th,\alpha\%}$, on rejette H_0 au seuil α ⇔ il y a stationnarité ;
- Sinon on ne rejette pas H_0 ⇔ il n'y a pas de stationnarité, et la VaR historique renverrait un résultat faussé.

- Test KPSS (Kwiatkowski-Phillips-Schmidt-Shin) :

On considère la série $r_t = \alpha t + \mu_t + \varepsilon_t$ où
αt est une composante "déterministe"
μ_t est une composante "stochastique" : $\mu_t = \mu_{t-1} + u_t$ où les $u_t \sim (0, \sigma_u^2)$ sont i.i.d
ε_t est un bruit "stationnaire" : $\varepsilon_t \sim (0, \sigma_\varepsilon^2)$ sont i.i.d

Comme αt est une composante déterministe, et que ε_t est stationnaire, on cherche à savoir si la composante μ_t est stationnaire ou non.
$H_0 \coloneqq \sigma_u^2 = 0$ (la composante stochastique est stationnaire, car sous H_0, $\mu_t = \mu_0$ est une constante)
$H_1 \coloneqq \sigma_u^2 > 0$ (la composante stochastique n'est pas stationnaire)

Sous H_0, la statistique est : $KPSS = \frac{1}{n^2}\sum_{t=1}^{n}\frac{S_t^2}{\widehat{\sigma_\infty^2}}$ où
- $S_t = \sum_{j=1}^{t}\widehat{\varepsilon_h}$ est une somme partielle sur les résidus $\widehat{\varepsilon_h}$ (résidus qui sont calculés par MCO sous l'hypothèse H_0, car le modèle est alors linéaire $r_t = \alpha t + \mu_0 + \varepsilon_t$) ;
- $\widehat{\sigma_\infty^2} = \widehat{\gamma_0} + 2\sum_{h=1}^{l}\omega_h\widehat{\gamma_h}$ est une estimation de la variance à long terme des résidus (= une version augmentée de la variance que nous connaissons $Var(\hat{\varepsilon}) = \frac{1}{n}\sum_{h=1}^{n}(\widehat{\varepsilon_h} - \bar{\hat{\varepsilon}})^2$), où
  - $\widehat{\gamma_h}$ représente les autocovariances empiriques ;
  - ω_h représentent des poids décroissants ;
  - l représente le nombre de "lags"/décalages retenus (choisi selon une règle).

La règle de décision est :
- Si $KPSS \geq KPSS_{th,\alpha\%}$, on rejette l'hypothèse H_0 au seuil α ⇔ il n'y a pas de stationnarité ;
- Sinon on ne rejette pas H_0 ⇔ il y a stationnarité des rendements.

Note : la distribution de la statistique KPSS n'a pas de forme analytique fermée, comme pour la statistique ADF ou Shapiro-Wilk.

Outil graphique pour visualiser la stationnarité :

Définition d'une fenêtre glissante : si l'on a 1 000 jours de données, on peut les séparer en plusieurs intervalles successives de 21 jours/100 jours/10 jours/... sur lesquelles on peut donc visualiser l'évolution d'un paramètre (ex : moyenne, volatilité, etc.) au cours de ces intervalles ; c'est ce qu'on appelle la "fenêtre glissante".
Par exemple, si l'on décide d'une fenêtre glissante de 21 jours, le calcul de la volatilité est le suivant :

1. 1er jour : calcul de la volatilité sur les jours [1 ;21],
2. 2e jour : calcul de la volatilité sur les jours [2 ;22],
3. 3e jour : calcul de la volatilité sur les jours [3 ;23],
4. Etc.

Note : les valeurs des écart-types ne commencent qu'à partir du jour n°21 ici, car le premier écart-type est calculé sur les 21 premiers jours (donc il n'apparaît qu'au bout des 21 premiers jours, soit le 21e jour). De même, le deuxième écart-type calculé est associé au jour n°22 (car le calcul prend en compte les jours n°2 à n°22 inclus).

Dans le cadre de l'hypothèse de stationnarité, on s'intéresse à savoir si la volatilité est "constante" ou non.
Ici, on va calculer la volatilité comme l'écart-type des rendements logarithmiques :
$\sigma_{[t;t+21]} = \sqrt{\frac{1}{21}\sum_{k=0}^{21}\left(r_{t+k} - \overline{r_{[t;t+21]}}\right)^2}$ où :

- $\sigma_{[t;t+21]}$ dénote l'écart-type sur l'intervalle [t ;t+21], soit l'écart-type sur les jours n°t à n°t+21,
- r_{t+k} est le rendement logarithmique au jour n°t+k, $r_{t+k} = \log\left(\frac{S_{t+k}}{S_{t+k-1}}\right)$,
- $\overline{r_{[t;t+21]}}$ est la moyenne des rendements logarithmiques sur l'intervalle [t ;t+21].

Note : ici, dans notre code, les rendements logarithmiques ont été multipliés par 100 (1% est écrit comme "1" au lieu de "0,01"). Donc les écart-types calculés ont été multipliées par un coefficient de 100 : un écart-type de 2% est ici écrit comme "2" au lieu de "0,02".
En effet, on a :

$$\sigma'_{[t;t+21]} = \sqrt{\frac{1}{21}\sum_{k=0}^{21}\left(100r_{t+k} - 100\overline{r_{[t;t+21]}}\right)^2}$$

$$\Leftrightarrow \sigma'_{[t;t+21]} = \sqrt{\frac{1}{21}\sum_{k=0}^{21}100^2\left(r_{t+k} - \overline{r_{[t;t+21]}}\right)^2}$$

$$\Leftrightarrow \sigma_{[t;t+21]} = \sqrt{\frac{100^2}{21}\sum_{k=0}^{21}\left(r_{t+k} - \overline{r_{[t;t+21]}}\right)^2}$$

$$\Leftrightarrow \sigma'_{[t;t+21]} = 100\sqrt{\frac{1}{21}\sum_{k=0}^{21}\left(r_{t+k} - \overline{r_{[t;t+21]}}\right)^2}$$

$$\Leftrightarrow \sigma'_{[t;t+21]} = 100\sigma_{[t;t+21]}$$